Proposta de Projeto: Dinâmica e Evolução Temporal de Comunidades no MathOverflow

Gabriela Soares Dias de Almeida, Matheus Flavio Gonçalves Silva, Rodrigo Viana Souza, Victor Yuji Yano

1. Descrição do Problema e Relevância em Computação Social

Em plataformas de perguntas e respostas (Q&A) técnicas como o MathOverflow, o suporte mútuo e a resolução de problemas dependem de interações descentralizadas entre os usuários. Diferente de redes sociais tradicionais com foco em conexões bilaterais estáveis (como amizades ou seguidores), as redes de colaboração técnica são moldadas por demandas pontuais que variam no tempo. Isso gera estruturas sociais fluidas, onde grupos coesos de discussão emergem em torno de tópicos específicos e se reorganizam conforme o interesse dos participantes muda ou usuários experientes deixam a plataforma.

Compreender a evolução dessas comunidades ao longo do tempo é um problema central em Computação Social. A literatura recente aponta que a sustentabilidade de ambientes abertos depende tanto da formação de núcleos densos de especialistas quanto da capacidade de absorver novos membros sem fragmentar a rede. Este projeto investiga como as comunidades do MathOverflow se formam, fundem, dividem ou se dissolvem ao longo de mais de seis anos de histórico contínuo.

Buscamos responder a três questões centrais:

1. As subcomunidades detectadas mantêm estabilidade estrutural ao longo dos anos ou operam sob alta rotatividade de nós (turnover)?
2. Eventos de fusão (*merge*) e divisão (*split*) de comunidades estão associados à sobrecarga ou à saída de usuários altamente centrais?
3. Há diferenças na dinâmica temporal quando comparamos interações orientadas a resolução direta (respostas a perguntas) versus interações de debate (comentários)?

Trabalhos Relacionados

A detecção estática de comunidades em grafos é amplamente coberta por métodos clássicos de otimização de modularidade, como o algoritmo de Louvain (Blondel et al., 2008) e Infomap

(Rosvall & Bergstrom, 2008). No entanto, abordagens estáticas ignoram a volatilidade das conexões em sistemas colaborativos.

Para redes dinâmicas, Palla, Barabási e Vicsek (2007) definiram o arcabouço canônico para rastrear comunidades ao longo de fatias de tempo (snapshots), demonstrando que grupos maiores exigem rotatividade contínua de membros para persistir, enquanto grupos menores tendem à estagnação se perderem membros fundadores. No contexto específico da família Stack Exchange, Paranjape, Benson e Leskovec (2017) mostraram que motivos temporais de fechamento triádico ocorrem em escalas de horas a poucos dias, mas ainda há lacunas na análise de como esses micro-padrões agregam-se em transformações macroscópicas na estrutura das comunidades em janelas de múltiplos anos.

2. Metodologia

2.1 Base de Dados

Utilizaremos o dataset temporal `sx-mathoverflow`, disponibilizado pelo repositório SNAP (Stanford). A base contém 506.550 interações dirigidas ocorridas ao longo de 2.350 dias (~6,4 anos) entre 24.818 usuários, registradas com granularidade de segundos via timestamp Unix. Os dados cobrem três modalidades de arestas:

- Respostas a perguntas (*answers-to-questions*): 107.211 arestas
- Comentários em perguntas (*comments-to-questions*): 157.380 arestas
- Comentários em respostas (*comments-to-answers*): 241.959 arestas

2.2 Procedimento Experimental

O pipeline analítico será implementado em Python (utilizando NetworkX, CDlib e scipy) estruturado em três etapas:

1. **Particionamento Temporal:**
   A série temporal de interações será segmentada em janelas discretas de tempo fixo. Avaliaremos duas resoluções: janelas semestrais (180 dias) e anuais (365 dias), com janelas deslizantes com 50% de sobreposição para suavizar efeitos de fronteira. Em cada janela t, construímos um multigrafo dirigido ponderado pelo número de interações entre cada par de usuários (u, v).

2. **Detecção e Rastreamento de Comunidades:**
   Empregaremos o algoritmo de Leiden/Louvain em cada fatia t para particionar os grafos em comunidades, medindo a modularidade (Q) obtida. O ciclo de vida das comunidades será rastreado entre fatias sucessivas t e t+1 por meio do índice de similaridade de Jaccard entre os conjuntos de nós. Seguindo a taxonomia clássica de eventos dinâmicos, mapearemos: sobrevivência, nascimento, morte, fusão (quando duas comunidades em t convergem para uma em t+1) e divisão (quando uma comunidade se fragmenta).
3. **Caracterização Topológica e Papéis dos Usuários:**
   Para cada comunidade ao longo do tempo, calcularemos: densidade interna, razão de condução (*conductance*) e taxa de rotatividade de nós. Para identificar membros críticos, calcularemos centralidade de intermediação (*betweenness*) e PageRank ponderado. Verificaremos se nós com alta centralidade que atuam como pontes entre tópicos reduzem a probabilidade de fragmentação das comunidades em que estão inseridos.

3. Resultados Esperados

Ao final do projeto, esperamos entregar:

1. **Curvas de Longevidade e Ciclo de Vida:** Gráficos de sobrevivência e fluxos de Sankey/Alluvial ilustrando a linhagem das principais comunidades do MathOverflow ao longo dos 2.350 dias.
2. **Impacto do Desligamento de Especialistas:** Quantificação empírica de como a saída ou redução de atividade dos 5% de nós mais centrais afeta a coesão das comunidades nas janelas seguintes.
3. **Comparação de Camadas de Interação:** Determinação de se a rede de comentários possui comunidades mais dispersas e instáveis que a rede formada apenas por respostas a dúvidas.
4. **Relatório Final e Código:** Código reproduzível em repositório estruturado, apresentação de 20 minutos com dados empíricos consolidados e o relatório final de 5 páginas.

Página Extra: Detalhamento do Uso de IA Generativa

O uso de IA generativa na elaboração desta proposta concentrou-se estritamente na fase de planejamento e delimitação técnica do escopo, conforme discriminado a seguir:

- **Avaliação de Viabilidade dos Dados:** Consultou-se a ferramenta para contrastar a estrutura interna dos datasets do SNAP (`sx-mathoverflow` vs. `github-social`), verificando a presença de carimbos temporais contínuos no formato de arestas do MathOverflow e confirmando a inadequação do grafo do GitHub para análise dinâmica longitudinal.
- **Refinamento de Hipóteses:** A ferramenta foi utilizada como contraponto crítico na discussão sobre quais variáveis de rede (como *betweenness* vs. grau puro) seriam mais informativas para explicar fenômenos de fusão e fragmentação de comunidades.
- **Mapeamento de Ferramentas:** Utilizou-se o modelo para identificar bibliotecas consolidadas em Python que já implementam rastreamento de eventos dinâmicos de comunidades (especificamente o ecossistema CDlib), evitando a necessidade de construir algoritmos de pareamento de Jaccard do zero durante o período do projeto.
- **Revisão Textual:** O texto final da proposta foi revisado para manter boa ortografia.